

A avaliação como operação de medida: fidedignidade, validade e planejamento de testes escolares

AULA

6

Metas da aula

Discutir as noções de fidedignidade e validade no contexto da avaliação como operação de medida.
Apresentar as principais fases do planejamento de testes escolares.

objetivos

Esperamos que, após o estudo do conteúdo desta aula, você seja capaz de:

- Dominar noções específicas de avaliação como operação de medida, tais como fidedignidade e validade.
- Dominar fases do planejamento de testes escolares.

Pré-requisito

Para que você compreenda melhor esta aula, é importante que tenha amplo domínio teórico da Aula 5.

INTRODUÇÃO

Na aula anterior, referente à avaliação como operação de medida, procuramos desenvolver o conceito desta tendência de avaliação como sinônimo de medição, entendendo por medição a determinação ou verificação da extensão, medida ou grandeza de alguma coisa com base numa escala fixa. Queremos agora ir um pouco mais além. Nossa meta é discutir algumas noções do âmbito da avaliação como operação de medida e apresentar-lhe as principais fases do planejamento de testes escolares.

O que justifica a presente aula é o desconhecimento dessas noções e fases, sobretudo pelos mais novos na carreira docente. Os efeitos disso na prática são vários, mas especialmente dois são mais salientes: a proliferação de questões e testes mal elaborados e os conseqüentes prejuízos para os alunos, entre os quais se podem incluir as dificuldades de resolver corretamente certas questões, não porque não saibam, mas por se distanciarem do que os avaliadores esperam.

Todavia, vamos argumentar que somente saber construir questões e testes com fidedignidade e validade, bem como estar atento às fases do planejamento dos testes escolares, não dá conta do essencial a ser avaliado.

Nosso objeto de estudo se constitui, portanto, das noções de fidedignidade e validade e das fases do planejamento dos testes escolares. Por causa desse recorte, o modo de construir questões torna secundária a idéia de discutir diferentes modos de elaborar questões. Além disso, estamos convictos de que a discussão e o domínio de ambas as noções e das principais fases de planejamento dos testes têm mais contribuições importantes para a educação das nossas crianças e jovens.

AS NOÇÕES DE FIDEDIGNIDADE E VALIDADE

O verbete *fidedigno* indica aquilo que é digno de fé, que merece confiança. O grau de fidedignidade de alguma coisa evidencia os níveis de confiança que a mesma é capaz de inspirar. Assim, quanto maior é este grau, tanto maior é o nível de confiança que pode merecer.

Em termos de avaliação como operação de medida, a fidedignidade de uma questão em particular, ou de um teste em geral, tem a ver com a estabilidade dos seus resultados. Na prática, quando construímos uma dada questão, ou elaboramos um teste, a expectativa é de que as respostas não variem de um grupo de alunos para outro.

Você já pensou se as questões de múltipla escolha, por exemplo, fossem destituídas de fidedignidade? E se em diferentes oportunidades as respostas dos alunos a elas não fossem sempre as mesmas?

Pense agora num mesmo teste, aplicado aos mesmos alunos mais de uma vez. Suas respostas seriam sempre as mesmas? Teriam eles, sempre, os mesmos desempenhos?

Ora, se as respostas não são sempre as mesmas e os desempenhos que traduzem variam muito toda vez que se aplica o mesmo teste com as mesmas questões, alguma coisa está muito errada. Quando isso ocorre, em muitas ocasiões a tendência genérica é transferir culpas para os alunos: “Eles não estudam!”, “São preguiçosos” etc. Quase sempre, porém, os problemas estão nas próprias questões, as quais geralmente são formuladas indevidamente.

ATIVIDADE



1. Tomando como base a questão que vem a seguir, faça as devidas modificações visando garantir o máximo de validade e fidedignidade.

A capital do estado do Rio de Janeiro é a sede de quatro dos mais importantes times de futebol do Brasil. Qual é o mais importante e querido dentre eles?

- a) Botafogo
- b) Flamengo
- c) Fluminense
- d) Vasco da Gama

COMENTÁRIO

Esta questão, como se pode ver, admite respostas diferentes, dependendo da paixão futebolística de cada aluno. Na prática, porém, é uma questão pobre; quando muito, servirá apenas para discriminar os alunos que são torcedores do Botafogo, Flamengo, Fluminense e Vasco.

Obviamente, a questão poderia ser formulada de outras maneiras. Nossa preocupação, entretanto, é demonstrar como se pode alterar uma questão para lhe proporcionar mais estabilidade, com a finalidade de impedir que os alunos “errem” pelo simples fato de não terem a mesma paixão clubística que o elaborador do instrumento de medida.

Uma sugestão de resposta seria:

A capital do estado do Rio de Janeiro é a sede de quatro importantes times de futebol do Brasil: Botafogo, Flamengo, Fluminense e Vasco da Gama. Assinale o par que já esteve na segunda divisão do futebol brasileiro:

- a) Botafogo e Vasco
- b) Fluminense e Flamengo
- c) Flamengo e Vasco
- d) Botafogo e Fluminense

Bem diferente da formulação anterior, a despeito da paixão futebolística do aluno, a resposta correta é a alternativa “d”.

DISCRIMINAR

É estabelecer diferenças; distinguir: discriminar entre o erro e o acerto. A avaliação como operação de medida trabalha com índice de discriminação. O *índice de discriminação (ID)* é a diferença entre os percentuais de acerto dos 27% de alunos de melhor desempenho e dos 27% de alunos de pior desempenho. Toda vez que o ID é menor que 25, significa que não discrimina adequadamente.

CALIBRAR

Significa medir o calibre, isto é, a dimensão, o volume, o tamanho ou a espessura de alguma coisa. Mais comumente usamos a palavra quando medimos o volume de ar dos pneus dos nossos carros e restabelecemos o nível considerado ideal.

A questão apresentada jamais se prestaria a medir o grau de conhecimento de cada um, menos ainda a **DISCRIMINAR** quem sabe de quem não sabe.

Para assegurar o adequado índice de discriminação de uma questão em separado, ou de um teste como um todo, torna-se indispensável, então, que sejam **CALIBRADOS**. No processo de calibragem de um e de outro, o ideal é a obtenção dos mesmos resultados toda vez que a questão e o teste são aplicados ao mesmo grupo, em condições semelhantes. Para tanto, torna-se necessário mexer na questão ou no teste diversas vezes. A idéia é ir fazendo acertos até que se obtenha um padrão de resposta. A repetição dos escores, portanto, será o principal indicador do grau de fidedignidade que queremos obter.

Estatisticamente é possível definir a fidedignidade perfeita de uma questão e de um teste, sem importar que formatos tenham as questões objetivas: múltipla escolha, lacunas, colunas, completar palavras etc. Nesta perspectiva, Vianna (1973, p. 146), com base em Ebel (1965), nos diz que

a fidedignidade é o coeficiente de correlação entre dois conjuntos de escores obtidos independentemente, em formas paralelas do teste, para um mesmo grupo.

Nesta linha de raciocínio, a fidedignidade de uma questão ou teste (r_{xx}) é dada pela relação entre a variância do escore verdadeiro (s_v) e a do escore obtido (s_o). A variância do escore verdadeiro (s_v^2) é dada pela seguinte fórmula:

$$s_v^2 = s_o^2 - s_c^2$$

Por meio da seguinte relação, obtém-se a fidedignidade:

$$r_{xx} = s_v^2 / s_o^2$$

Vianna (1973, pp. 146-155) traz à consideração de seu leitor diversos métodos para o cálculo da fidedignidade. Recomendamos que recorra a eles, ou a outros métodos fornecidos pela Estatística, sempre que tiver necessidade de estabelecer a fidedignidade de uma questão ou de um teste.

NOTAS E ESCORES

Distinguir notas de escores, na opinião de G. de Lansheere (1974, pp. 17-18), é extremamente importante em Educação.

A nota, segundo o autor a entende, é uma síntese objetiva ou subjetiva que expressa dada performance, mas sempre em termos relativos. A atribuição de uma nota 10, que situa/posiciona o aluno em uma aferição qualquer, corresponde a uma síntese objetiva. Atribuir conceitos *bom* ou *excelente* ao mesmo aluno na mesma situação corresponderia a uma síntese subjetiva.

O escore, por sua vez, corresponde a resultados objetivos de testes ou outros instrumentos de medida. Regra geral é uma quantidade de acertos ou de erros alcançada segundo regras fixas.

Assim, segundo de Lansheere (1974), toda vez que um professor dá nota a um aluno, na verdade está atribuindo-lhe um escore.

O grau de validade de questões e testes, diferentemente do grau de fidedignidade, somente pode ser considerado *a posteriori*, em especial quando se tem certeza de que o conteúdo (da questão e/ou do teste) com o qual os alunos trabalharam está dominado. Na verdade, a validade, ocorre em relação a determinado propósito. Seu grau é, pois, bastante relativo. Daí é que uma questão ou teste pode ter validade apenas para determinados grupos de alunos, sendo totalmente inválido para outros.

Vianna (1973, p. 182), a respeito da noção de validade, nos diz que, para um teste ter validade, é preciso ser fidedigno e ter representatividade. Em sua perspectiva, a fidedignidade é condição necessária, mas não suficiente, para que haja validade. Somente há validade quando o teste é fidedigno e tem estabilidade comprovada em diversas amostras de alunos.

Como se pode ver, é extremamente válido que todos os professores dêem a devida consideração às noções de validade e fidedignidade. A atenção em ambas, no mínimo, os afastaria de alguns equívocos que, ao nosso ver, resultam em prejuízos para os alunos.

Contudo, somente ter bons índices de validade e fidedignidade não é suficiente. Sempre devemos levar em conta que a avaliação como operação de medida não constitui um fim em si mesma. A avaliação, qualquer que seja a tendência, afinal de contas, é apenas um meio a serviço da aprendizagem dos alunos. Nesse sentido suas funções primordiais devem servir para diagnosticar lacunas e fragilidades, porventura existentes, nos processos de ensino e aprendizagem, bem como indicar os níveis reais e potenciais dos alunos. Além disso, também devemos ter sempre em mente que, por mais fidedignos e válidos que sejam, os testes como instrumentos de medida nunca dão conta do essencial a ser avaliado.

Aliás, em processos de formação, somos favoráveis a que se dê atenção especial ao ensino de valores, assim como aos procedimentos de estudo, às estratégias de aprendizagem dos alunos e aos benefícios em longo prazo dos dispositivos de ensino e aprendizagem. Afinal, cabe-nos, como educadores, estar atentos ao tipo de homem/mulher que estamos formando, e para qual sociedade.

PLANEJAMENTO DE TESTES ESCOLARES

A realidade brasileira tem favorecido a improvisação no meio escolar. A falta de políticas públicas que promovam o professor, a qualidade do seu trabalho e da educação de crianças, jovens e adultos leva muitos deles a trabalhar em mais de um lugar para compor seus salários, e a improvisar tanto suas próprias aulas, quanto os testes aplicados aos seus alunos.

Lamentavelmente, é comum vermos professores preparando aulas em ônibus e em diversos outros lugares impróprios, copiando questões de testes em bancos de questões e até ditando ou escrevendo-as de improviso nos quadros-de-giz, enquanto os alunos transcrevem-nas lentamente para folhas de papel almaço. Porém, mais lamentável ainda é vermos que os processos de ensino, aprendizagem e avaliação, nessas bases, tornam-se comuns, naturais e, inclusive legítimos. O efeito imediato é muitos alunos serem reprovados, inclusive por não decodificarem o que têm diante de si, ou o que se lhes espera.

Por essas e diversas outras razões, o ofício docente precisa ser, *tem de ser provido* de seriedade e profissionalismo. Nessa linha de raciocínio, incluímos também os indispensáveis cuidados com os instrumentos de medida, isto é, com as questões e testes. Aliás, muito mais importante que os tipos de questões e testes, ou seja, como medir, é definir o que medir, com o maior grau de validade possível. Vianna (1973, p. 29), a esse respeito e com muita propriedade, nos ensina o seguinte:

Um teste de medida educacional não é uma coisa meramente física; ao contrário, traduz um processo humano (DYER, 1960), que envolve julgamento humano desde as suas fases iniciais até o seu término, exigindo tempo, esforço e pensamento criativo. Tempo para planejá-lo em todos os seus detalhes, esforço para tomar decisões cruciais sobre o que incluir ou omitir no teste, sobre o que é importante ou secundário, sobre o que deve ser

considerado correto e, finalmente, criatividade para apresentar situações engenhosas que possam refletir as diferentes mudanças ocorridas durante o processo educacional.


Dito isto, vale ressaltar bem a importância do *tempo*, do *esforço* para tomar decisões e da *criatividade*, em todas as fases no planejamento dos testes escolares, a despeito de quantas sejam tais fases. Além disso, acreditamos ainda ser fundamental somar a esta tríade a preocupação com a possibilidade de exigir o máximo de informações dos alunos em um curto espaço de tempo, na maioria das vezes nunca superior a 50 minutos.

Primeira fase: o que medir?

Dada a matéria prevista no programa de formação, no tempo adequado, a questão que se impõe em algum momento é “O que medir?”, lembrando sempre que a matéria trabalhada não constitui a finalidade de tal programa, ela é sempre um meio. No mínimo, espera-se que seja instrumento importante para novas leituras de mundo, para novos modos de ser, estar, fazer e conviver.

Segundo a opinião de Vianna (1973, p. 29), com a qual concordamos, é desejável que

o examinando, por meio de comportamentos observáveis, demonstre que há sensível diferença entre o momento de então anterior à educação formal, e o momento de agora, que deve refletir, necessariamente, o efeito da ação educativa.



Segunda fase: como medir?

Tendo definido o que medir, a preocupação seguinte é com o “como medir?”, qual o formato das questões e do próprio teste? As questões serão fechadas ou abertas? De quantas questões será constituído? Todas as questões vão ser do mesmo tipo?

Calma! Não entre em crise. Cuidado com o nível de estresse. Já vamos ajudá-lo!

Questões abertas

As questões abertas, hoje em dia, dividem o cenário avaliativo com as questões fechadas. A escolha por uma outra está ligada a diversos fatores, tais como tempo disponível, inspiração, criatividade, objetivos. Contudo, parece que a escolha por questões abertas tem a ver com a disposição de medir a extensão e a abrangência do conhecimento do aluno, bem como sua capacidade de verbalização.

As questões abertas são mais fáceis e rápidas para serem elaboradas. Aliás, são as perguntas mais naturais, mais presentes em nossa vida diária.

Quem inventou o avião?

Que Estados Imperialistas colonizaram a África?

Quantas eram as primeiras Capitanias Hereditárias?

Quantas caravelas constituíam a esquadra de Cristóvão Colombo?

Quais são os principais pintores do *Quattrocento* italiano?

Como você analisa o Tropicalismo?

Que avaliação faz das contribuições do Movimento Modernista à pintura brasileira?

Qual seu conhecimento sobre a produção do metanol?

As questões abertas, não obstante as possibilidades de extensão, abrangência e criatividade que proporcionam, por admitirem respostas únicas e subjetivas, apresentam alguns inconvenientes. De Landsheere (1976), por exemplo, afirma que “não se prestam bem à avaliação por comparação com as respostas de outros indivíduos” e, também, que não é verdade que sejam reveladoras de processos mentais superiores (p. 107). Com base em estudos publicados na Alemanha em 1972, o mesmo autor afirma ainda que as questões abertas, ao contrário do que se pensa, têm largo apelo à memória.

Questões fechadas

As questões fechadas, regra geral, são aquelas que levam os alunos a escolher a resposta correta, pelo menos entre quatro alternativas, ou distraidores, dispostas hierarquicamente, indo do mais absurdo ao mais plausível. Para efeito de ilustração, vejamos a seguinte questão:

Os primeiros povoadores do Brasil, provenientes da Europa, na era moderna, foram os:

- a) Irlandeses
- b) Espanhóis
- c) Fenícios
- d) Esquimós
- e) Portugueses

O enunciado desta questão (também denominado suporte, raiz ou premissa) é referente ao início do povoamento europeu do Brasil. A alternativa correta é, portanto, a letra “e”; as demais são distraidores. Dentre estes, a letra “d” possivelmente contém o maior absurdo. O mesmo ocorre, embora em grau menor, com a letra “c”. Não é absurdo, entretanto, que alguém defenda a tese da chegada dos fenícios ao Brasil; o absurdo, porém, está na data. De fato, os fenícios se notabilizaram como comerciantes marítimos-mediterrâneos e colonizadores na era antiga.

De Landsheere (1976, p. 115) ensina-nos ser necessário verificar se os distraidores desempenharão bem seus papéis. Segundo a perspectiva que aponta, é preciso calcular a percentagem de escolha que cada possibilidade de resposta será capaz de obter. Assim, nos momentos de pré-testagem, torna-se recomendável que dada questão seja ajustada até se chegar à seguinte situação ideal quanto à atração dos seus distraidores:

A	B	C	D	E
10%	10%	10%	60%	10%

Vejamos isto numa questão já aplicada aos alunos da 6ª série do Ensino Fundamental e da fase VI do Supletivo, matriculados na rede pública de ensino do estado do Rio de Janeiro.

Aos domingos, a primeira fornada de pão sai às 6h 30min, e a segunda sai às 8h 15min. O espaço de tempo entre as duas fornadas é de:

- a) 2h a5 min
- b) 2h 00min
- c) 1h 45min ©
- d) 1h 30min
- e) 1h 15min

Uma vez aplicada, observou-se que a alternativa correta (letra “c”), entre os alunos da 6ª série atraiu 36%, e entre os alunos do Supletivo atraiu 37%. Os distraidores “a”, “b”, “d” e “e” atraíram os alunos, respectivamente, conforme os seguintes percentuais: 46%, 05%, 04% e 08%, para os alunos da 6ª série, e 39%, 04%, 04%, 07%, para os do Supletivo.

O que isto quer dizer?

Depois de se ter ajustado a questão até se chegar à situação ideal quanto à atração dos seus distraidores, isto quer dizer que a questão apresenta dificuldade média, pelo fato de a opção a ter atraído fortemente 46% e 39% dos alunos, respectivamente, da 6ª série e do Supletivo. Segundo os organizadores desse teste, a forte atração da opção a, por sua vez, coloca em evidência a dificuldade que os alunos apresentam de operar com horas e minutos, ou mesmo o desconhecimento de como fazê-lo.

Terceira fase: pré-testagem

Nesta fase, é recomendável fazer uma pré-testagem das questões e do instrumento de medida em sua totalidade. Para tanto, sempre é possível trabalhar com uma amostra de indivíduos com características similares à do grupo de alunos.

A expectativa é, fundamentalmente, identificar itens defeituosos, graus de dificuldade e discriminação, tamanho do teste, tempo de realização, enfim, todas as inconsistências e incorreções porventura existentes.

Quarta fase: aplicação

Esta fase não é uma simples formalidade escolar. Ela supõe que o teste seja realizado em ambiente silencioso, com fácil circulação das pessoas, bem arejado e iluminado. Supõe ainda que todas as condições de aplicação sejam ótimas, garantindo tranqüilidade para os examinandos. Nesta fase, é também indispensável que a orientação aos examinandos seja adequada e precisa, tanto no que se refere ao melhor entendimento das questões, quanto à correta apresentação das respostas no caderno, folha ou cartão de respostas.

Quinta fase: correção

A correção das questões ou do teste, como um todo, é a última fase do planejamento dos testes escolares. Nesta fase, há professores que somente trabalham com as folhas e cartões de respostas, isto é,

unicamente com as respostas, sem considerar como os examinandos chegaram a elas. Estes professores, na falta de máquinas de leitura óptica, utilizam máscaras gabaritais. Outros professores, entretanto, mesmo usando tais máscaras, recorrem aos rascunhos dos alunos, na medida em que se mostram interessados em seus processos de resolução. Professores como esses, na verdade, privilegiam mais os processos mentais dos alunos.

Entre todos os professores, há também alguns que se inquietam com os acertos casuais em testes objetivos, os quais no jargão mais corrente constituem os “chutes” ou, também, os acertos com a ajuda de colegas próximos (“cola”). Em face disso, estes professores desenvolveram uma fórmula de correção (ou punição) para minimizar possíveis vantagens obtidas por meio de acertos casuais. A referida fórmula é expressa da seguinte maneira:

$$X_c = C - \frac{E}{n-1}$$

Onde: X_c = escore corrigido

C = número de acertos

E = número de erros

n = número de alternativas do item acertado casualmente

Sexta fase: comunicação dos resultados



Há várias maneiras de comunicar os resultados dos testes aos alunos. As piores certamente são aquelas que os expõem ao ridículo, com graves sensações de desconforto e constrangimento. Tais exposições incluem a leitura pública das notas dos alunos e a publicação de resultados em ordem de classificação, ambas seguidas de comentários geralmente humilhantes.

Muito já se falou sobre a leitura pública das notas. Contudo, sempre ainda cabe alguma palavra a respeito, sobretudo para lembrar aos jovens professores que seus alunos integram redes de relações familiares e sociais nas quais certos indicadores de sucesso/fracasso têm pesos consideráveis. Assim, torna-se aconselhável jamais haver essas leituras. Cabe a nós, professores, transmitir os resultados com toda discrição possível, tendo em mente que somente os alunos e familiares podem tornar públicos os desempenhos obtidos.

Perrenoud (1999, p. 148), a esse respeito, coloca em evidência a importante função comunicacional inerente aos resultados das avaliações escolares, lembrando-nos que os pais têm neles formidáveis pontos de referência para a regulação da vida de seus filhos. Na vida cotidiana, são muitas, de fato, as histórias de prêmios e castigos ligadas aos resultados dos testes escolares.

Sobre a publicação das notas com qualquer ordem de classificação, de igual modo, muito já se falou, salientando-se desde as estereotipações capazes de criar as exposições desnecessárias dos piores resultados. Perrenoud (1999, pp. 145-159), mais recentemente, tem ressaltado o peso das classificações na organização das turmas, nas escolhas das didáticas e dos métodos de ensino, nos sistemas de seleção e orientação e, também, nas satisfações pessoais e profissionais.

Em diversas instituições de ensino, as classificações e seus efeitos têm consideráveis impactos, muitas vezes negativos, sobre crianças e jovens em processos de formação. Assim, cabe a todos os professores e instituições de ensino tomar todos os cuidados, preferencialmente evitando hierarquizar seus alunos e acirrar as competições entre eles.

Em nosso próximo encontro, você verá como diversos aspectos que discutimos no presente texto podem ser aplicados à prática docente. Para tirar o maior proveito, procure fixar bem esta aula e a anterior.

RESUMO

As noções de fidedignidade e validade têm papel relevante no contexto da avaliação como operação de medida. Graças aos cuidados com uma e outra noção, os testes podem ser padronizados. Não é, porém, uma tarefa das mais fáceis a elaboração de um teste bem calibrado. Há pelo menos seis fases, que vão desde a definição do que medir até a comunicação dos resultados aos alunos e às suas famílias.

ATIVIDADE FINAL

Elaborar um teste com questões versando sobre um campo de conhecimento que você esteja dominando bem, mas de acordo com as fases do planejamento de testes escolares evidenciadas.

Tente, no entanto, fazer esta atividade com um grupo de colegas. A meta de vocês deve ser a elaboração de um teste fidedigno e válido.

This image shows a single page of white paper with horizontal blue or grey ruling lines. The lines are evenly spaced and run across the width of the page, leaving small margins at the top and bottom. There are no vertical margin lines, text, or other markings on the page.

AUTO-AVALIAÇÃO

Sua avaliação, lembre-se sempre, deve ser realizada em atenção aos objetivos propostos para esta aula. Assim, cabe a você, somente a você, responder se já:

Domina as noções de fidedignidade e validade.

Domina as fases do planejamento de testes escolares.